

Data Mining in the service of nmap

Sergey Ignatov, Omar “beched” Ganiev
sergey@ctf.su, beched@incsecurity.ru

Data Mining in the service of nmap
\$who



Мир не стоит на месте, все развивается, сетевые сканеры в том числе. Начиная от дедушки nmap 1.0 (September 1, 1997), сканеры развиваются в различных направлениях.

- Сканирование всего интернета (zmap)
- Сканирование уязвимостей в сервисах (nmap scripting engine и другие коммерческие сканеры безопасности)
- Интегрированный TCP стек (polarbear from IOActive)

Data Mining in the service of nmap

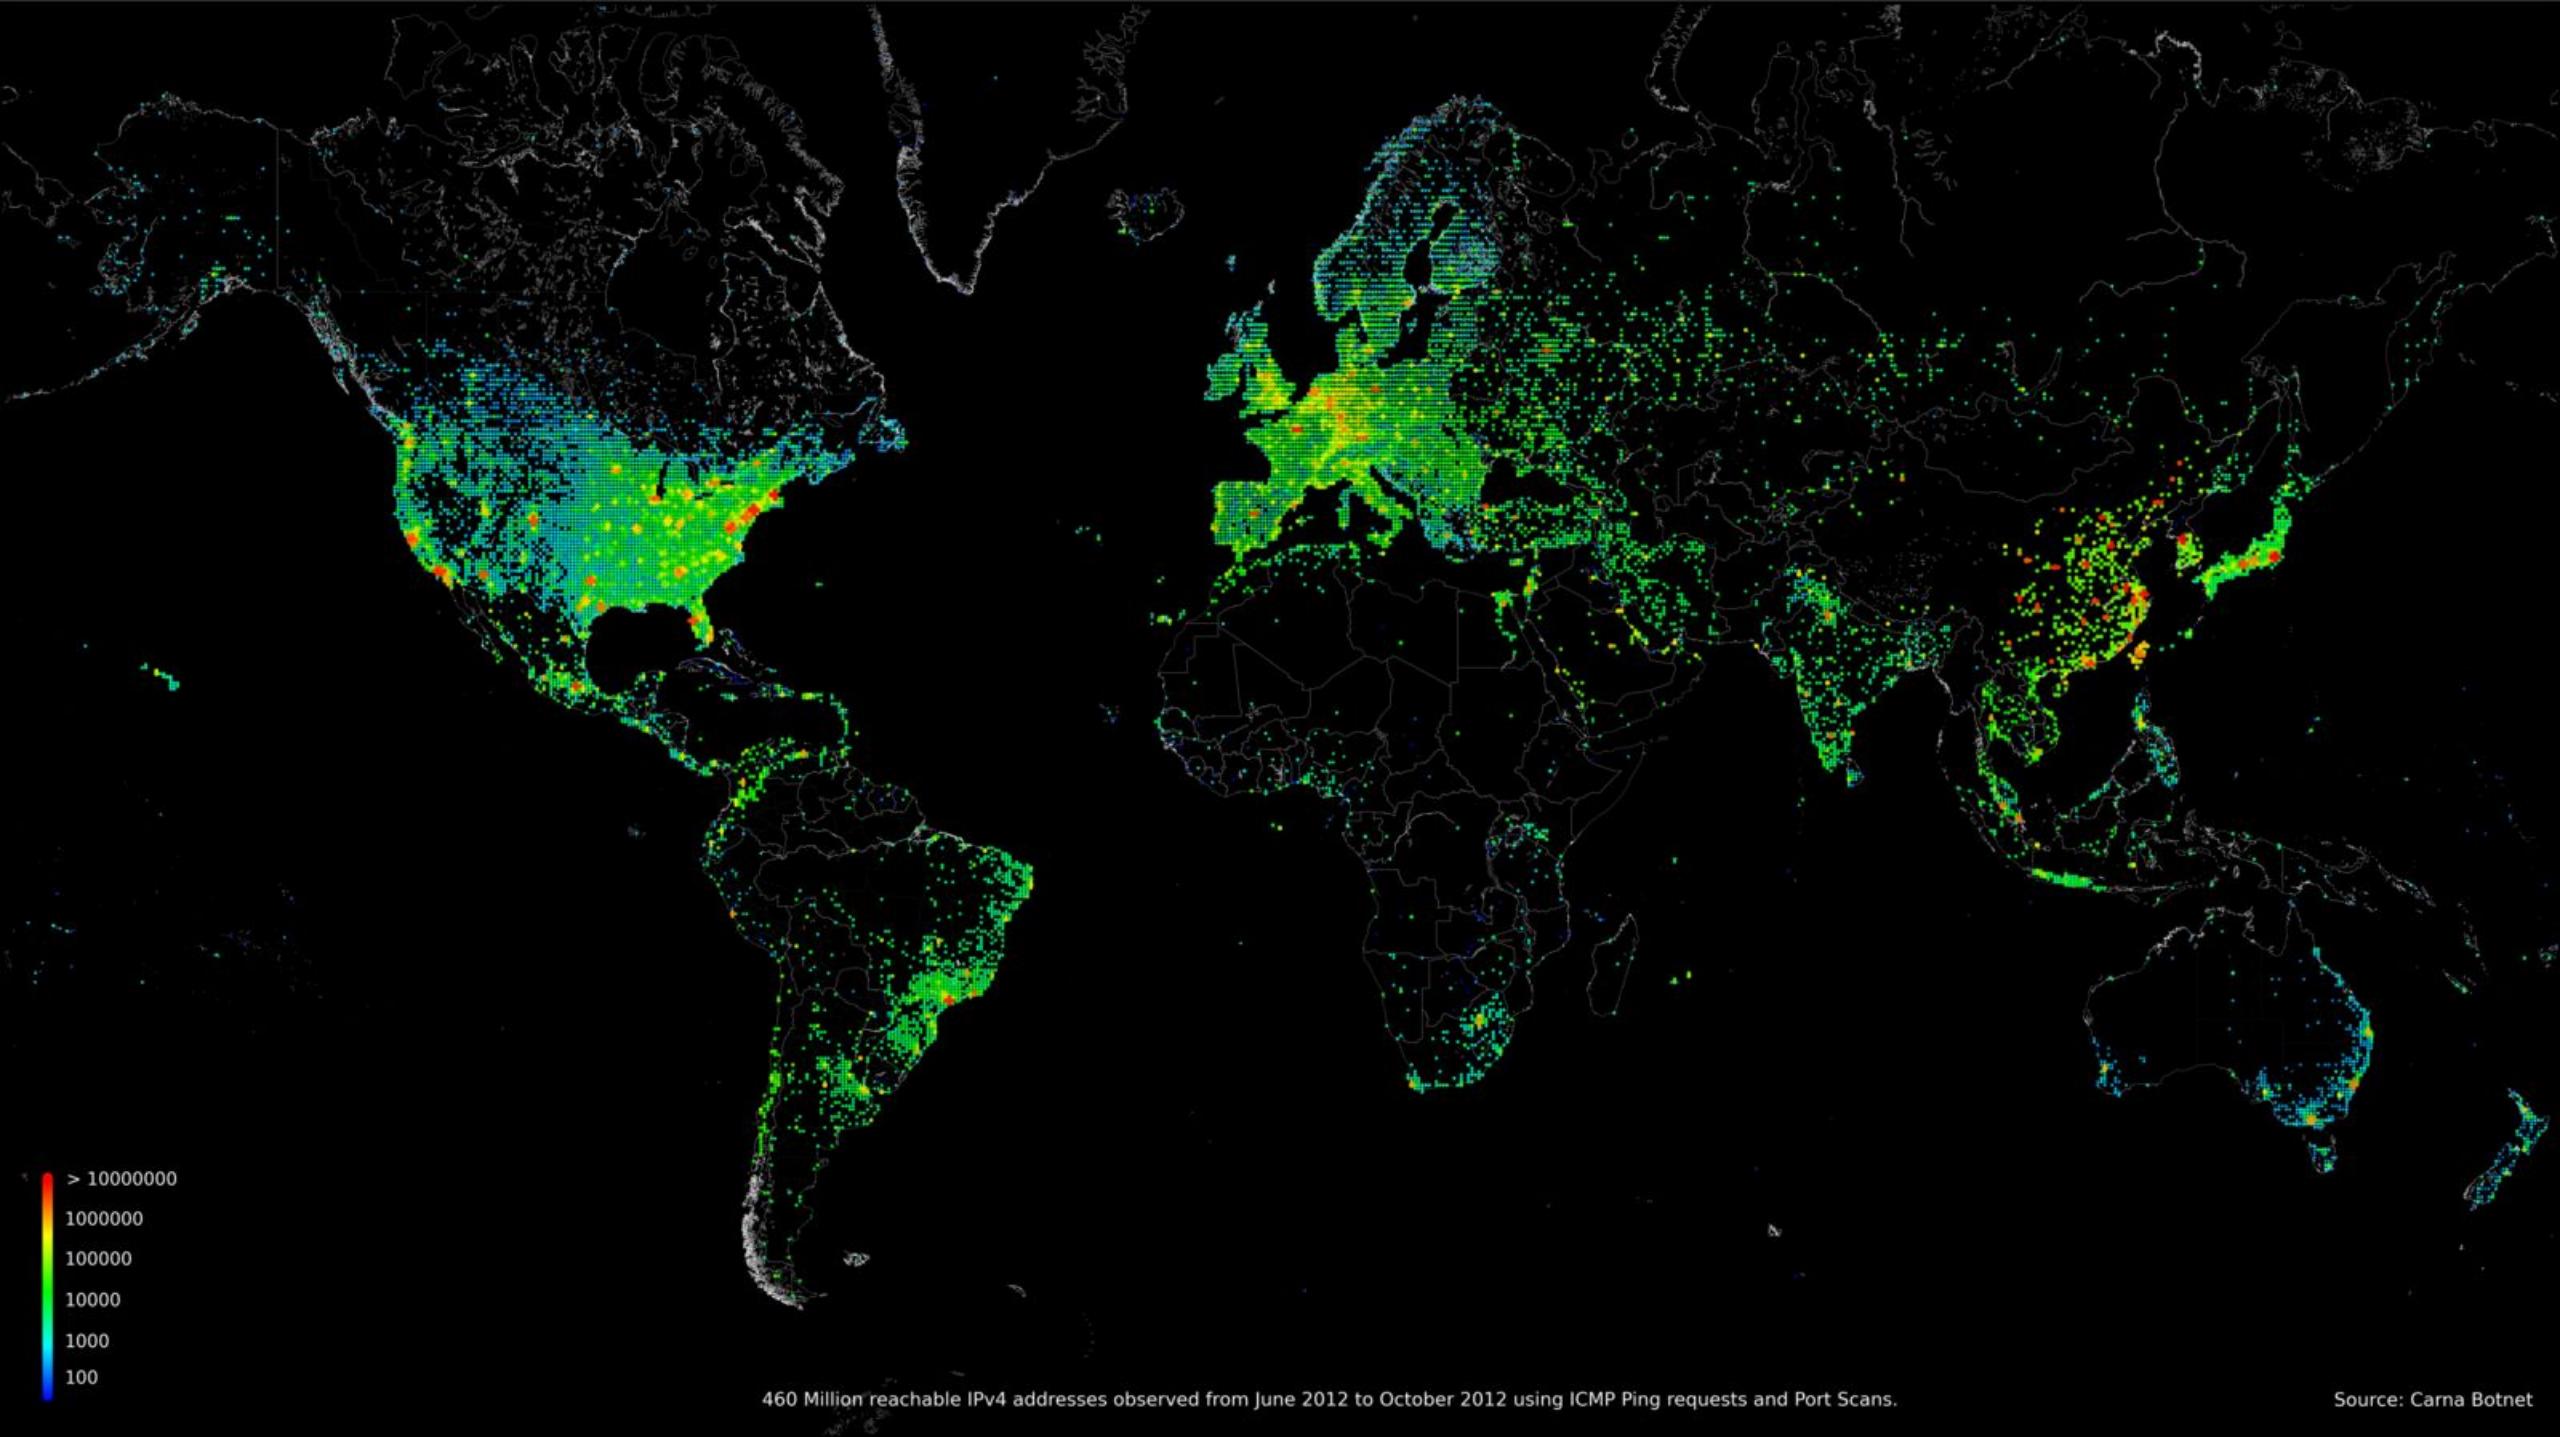
Но сканирования обнаруживаются IDS/IPS
:(

- Сканирование через сторонние сервисы (ftp bounce, proxy)
- Уязвимости в самом IDS/IPS
- Всякие сетевые хитрости (<https://nmap.org/book/man-bypass火walls-ids.html>)
- *Сканировать медленнее чем IDS хранит историю*
- Рассмотрим именно такой подход сканирования с задержками, мы хотим его сделать эффективнее

Как найти максимальное количество портов за минимальное количество запросов?

Data Mining in the service of nmap
Internet Census 2012

- <http://internetcensus2012.bitbucket.org>
- 420K взломанных домашних маршрутизаторов (пароли по умолчанию)
- Просканировали весь интернет!
- Dataset: 9TB of raw logfiles (500Gb in zpaq)



- На основе данных о всех хостах в интернете строим оракул, который будет предсказывать наиболее вероятные порты
- Идея очень проста: порты не встречаются сами по себе, они встречаются группами, так давайте хранить не список самых вероятных портов, а список самых вероятных групп

- По сути группы соответствуют различным классам сетевых устройств/сервисов
- Если нашли открытые порты X,Y и закрытый Z, то вероятнее всего будут открыты порты из групп где есть порты X или Y, и нет Z

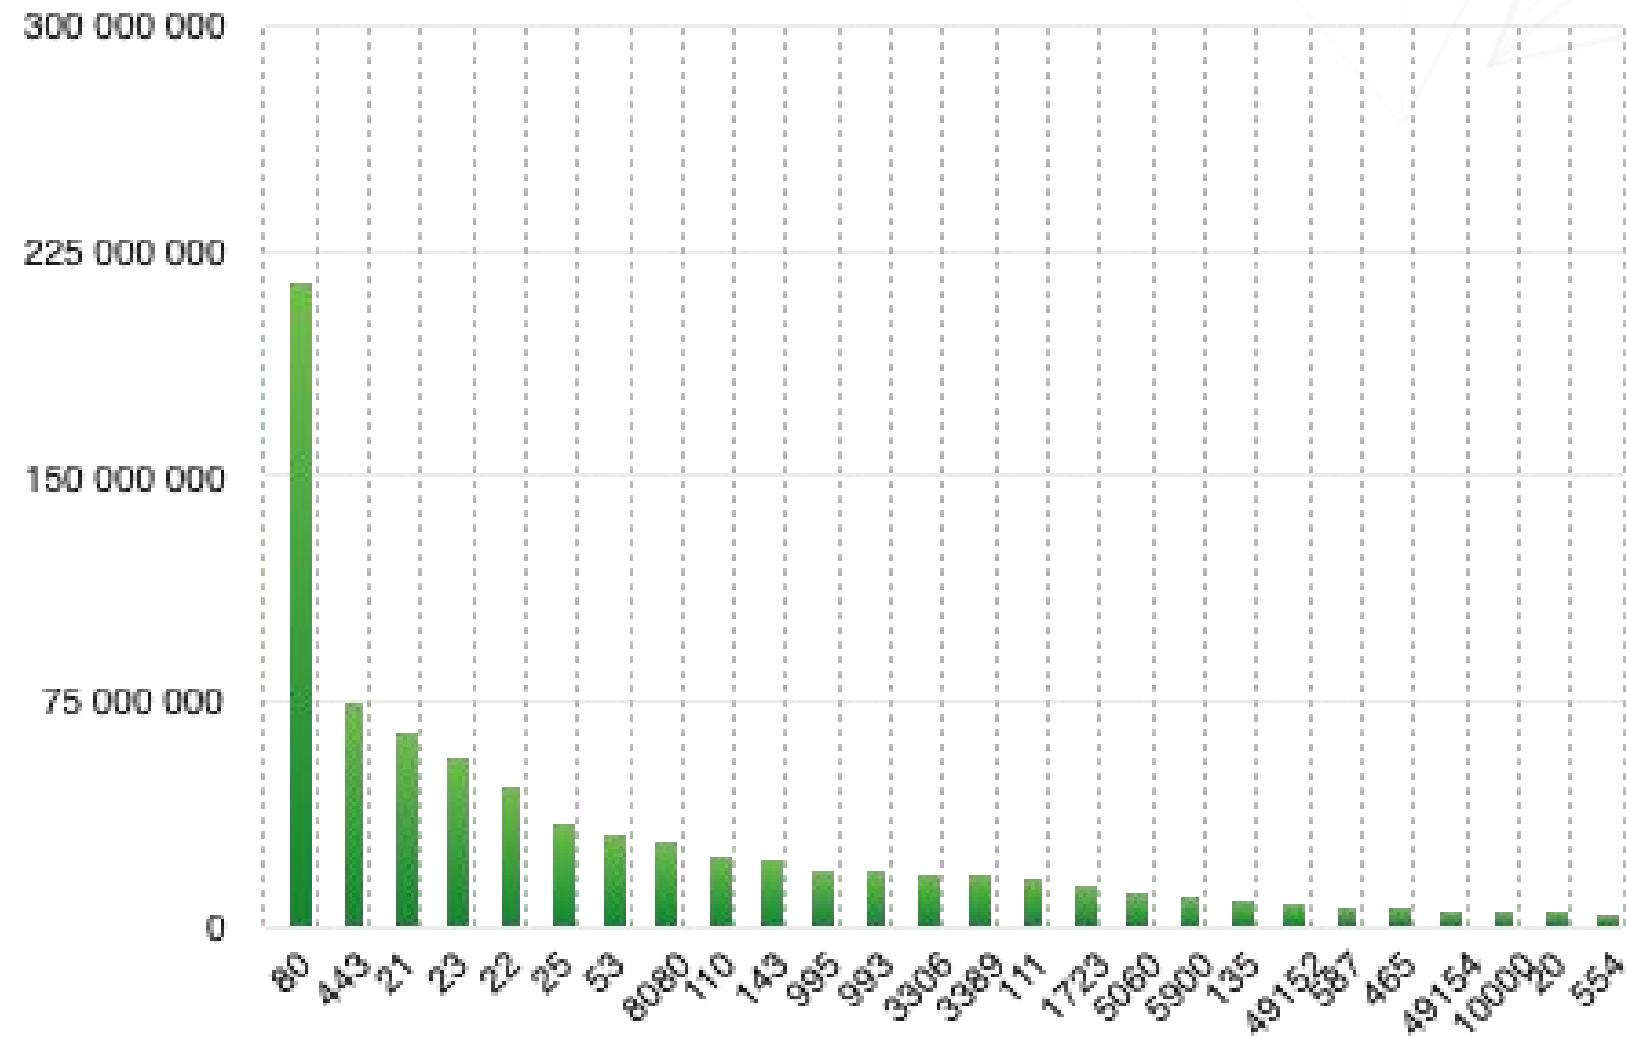
- Сначала мы пытались применить всякие умные алгоритмы и machine learning, делая вид, что умеем это
- Но дерево решений для сканирования будет экспоненциального размера, значит, его построение тоже экспоненциально
- Алгоритмы классификации не в тему

- Что ещё можно? Можно пробовать кластеризовать результаты скана и получить классы сервисов (“сайт”, “циска”, “винда”, ...)
- Проблема: в датасете интернет-скана много NAT-узлов, отправляющих обучение
- Проблема: в датасете много зафарволенных хостов, в которых виден только порт 80

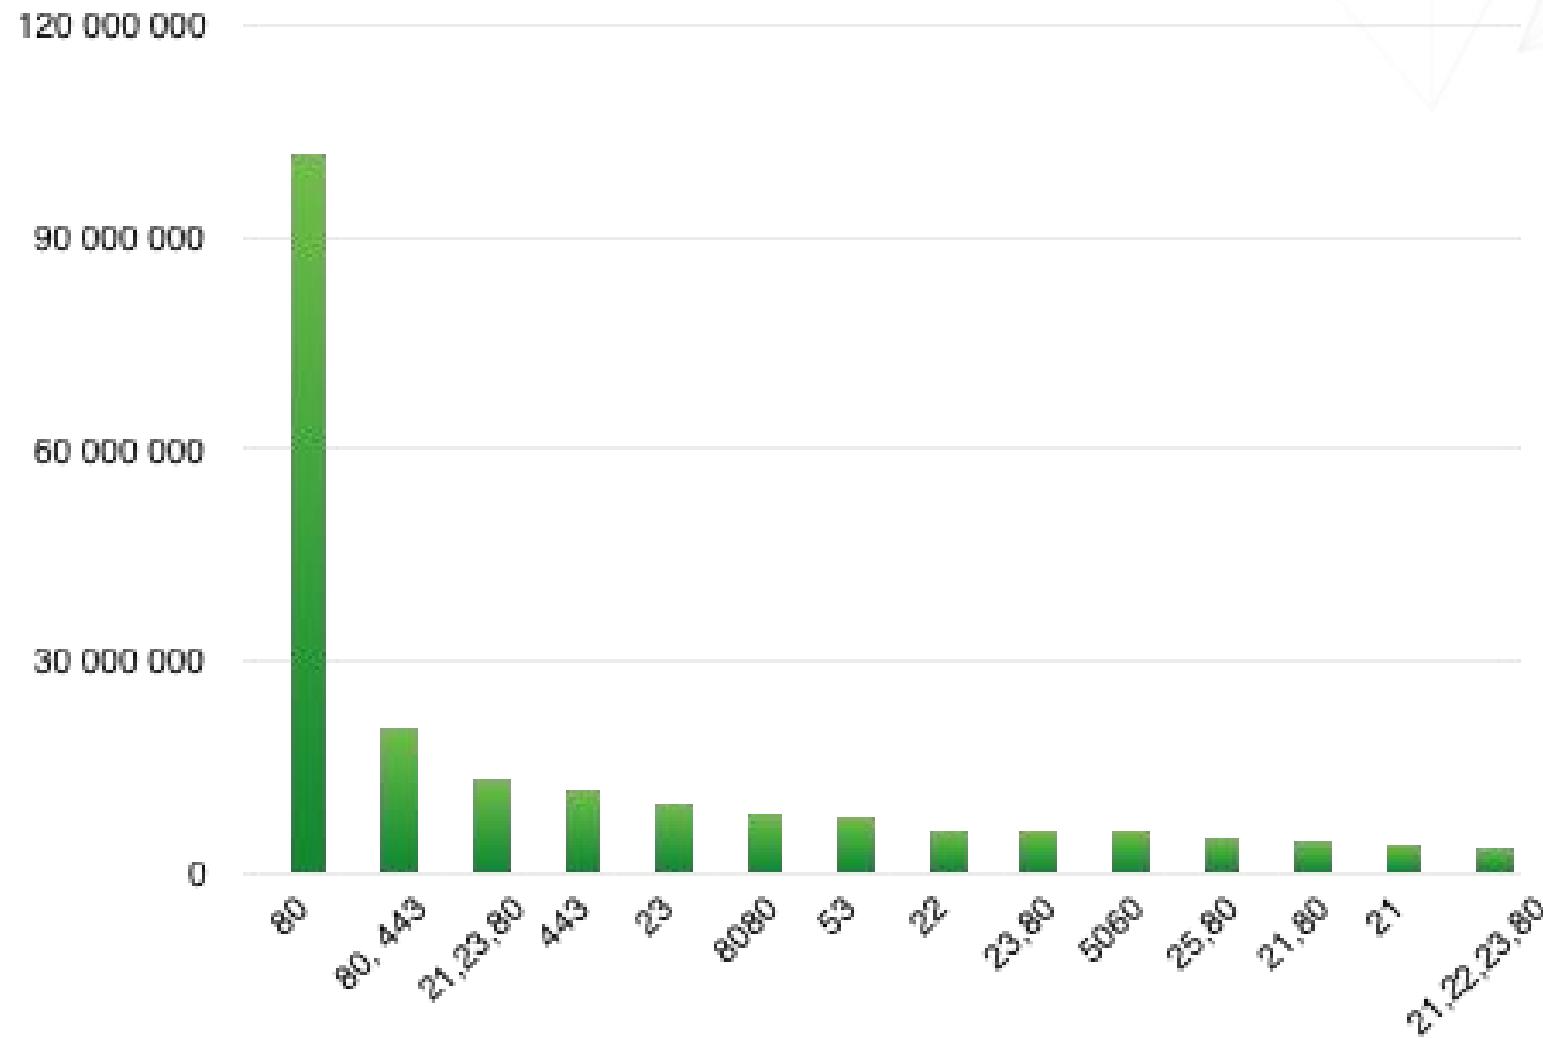
- Для кластеризации нужно метрическое пространство
- Можно взять какой-нибудь simhash, или можно взять длину LCS, которая динамически вычисляется за произведение длин последовательностей
- Но у нас около 10^7 уникальных последовательностей, а подходящая кластеризация работает не лучше чем за квадрат
- К тому же из NAT-последовательностей надо вычленять разумные подпоследовательности портов

- Keep It Simple, Stupid!
- Давайте просто сортировать статистику =)
- В качестве базовой статистики, по которой начинаем сканировать без предварительных знаний, для начала возьмём топ портов

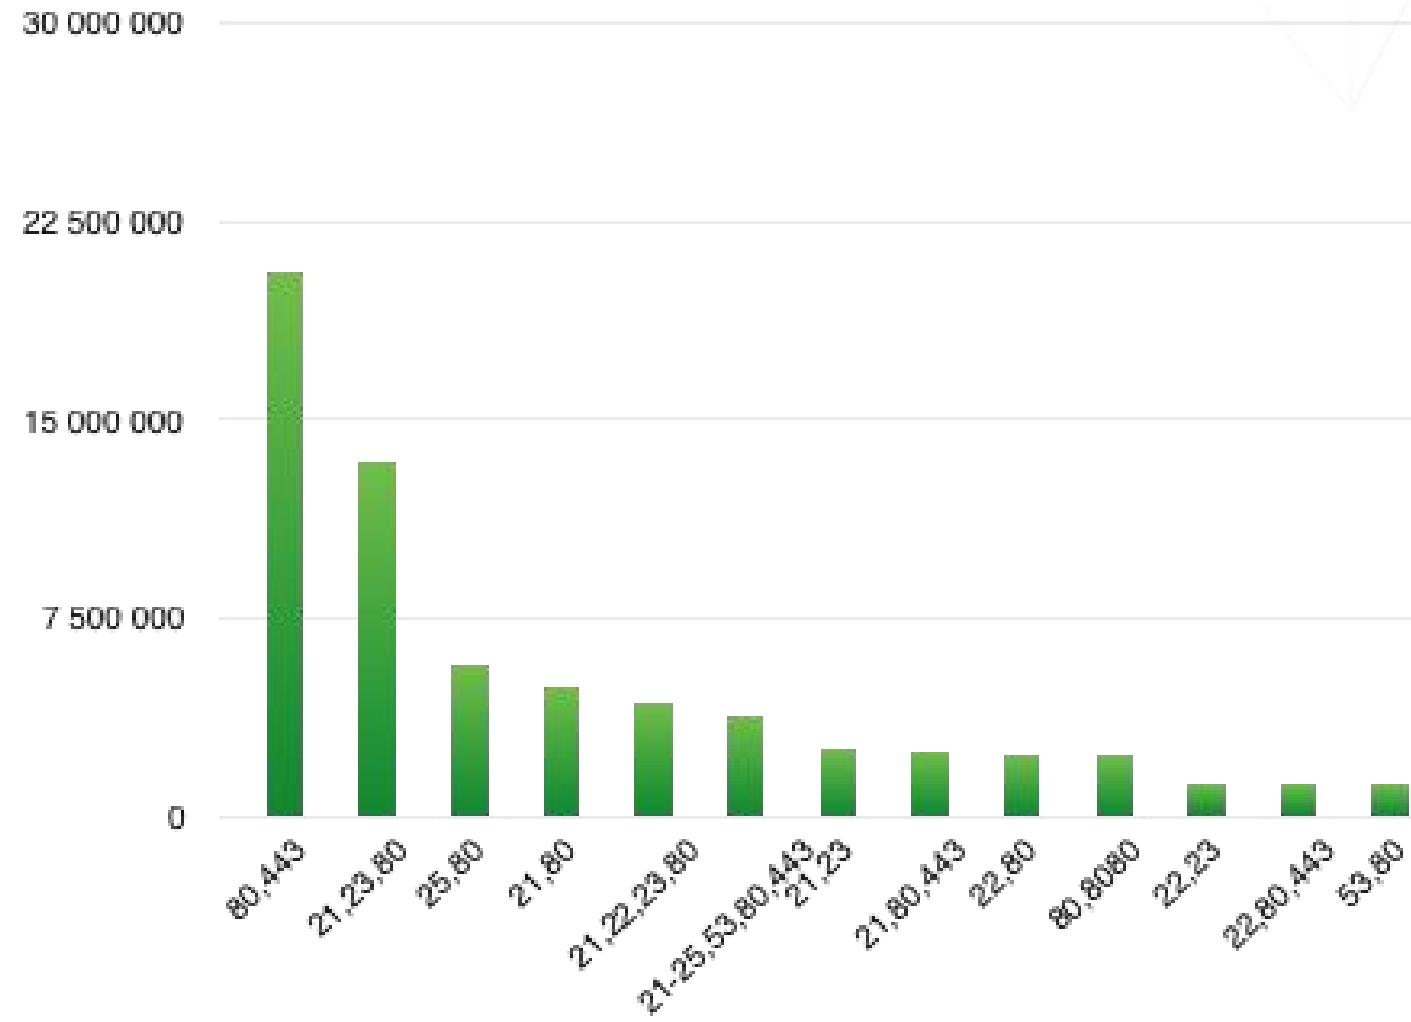
Data Mining in the service of nmap
Сколько открытых портов в интернете?



Data Mining in the service of nmap
TOP13 самых встречающихся групп



Data Mining in the service of nmap
TOP13 самых встречающихся групп

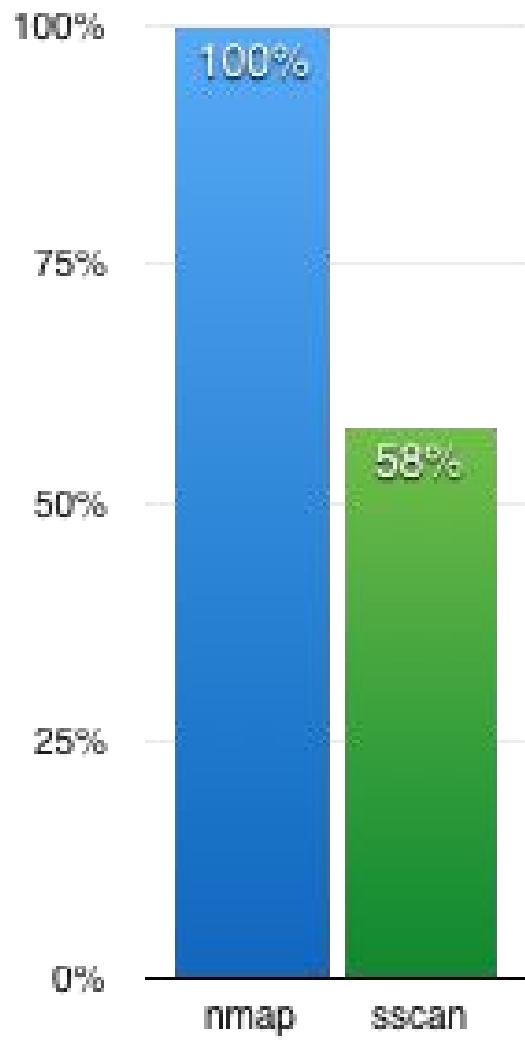


Data Mining in the service of nmap
Чем плох NMap?

- Чем плох NMap? Много чем, там много наследия прошлого
- Главное - он медленный
- По умолчанию NMap сканирует по топу портов (4243 порта),
при полном наборе сканирует случайнym образом

- Пока что с лобовым алгоритмом и предварительной статой уже получилось ускорение на 42% относительно NMap
- Статистику измеряли путём имитации сканирования
- При этом сравнивалось, за какое количество запросов наш алгоритм находит столько же портов, сколько всего нашёл NMap (по умолчанию он не ищет дальше своего топа)

Data Mining in the service of nmap
Результаты



- Патч для nmap, изменяющая стратегия сканирования
- Данные по интранету (внутренние пентесты)
- Компактный словарь
(сейчас 150Мб и самый полный 666Мб)
- Более точная кластеризация на основе данных протокола
(Тип сервиса, версия, ОС и т.д.)
- ...

Data Mining in the service of nmap
Вопросы

Q?

sergey@ctf.su

beched@incsecurity.ru